

刘元智

电话： 15769057937 | 邮箱： 1739727979@qq.com
年龄： 24岁 | 性别： 男 | 政治面貌： 共青团员

中国石油大学 CHINA UNIVERSITY OF PETROLEUM BEIJING

教育经历

中国石油大学(北京) 211 双一流 2024年09月 - 2027年06月
计算机技术 硕士 全日制

中国石油大学(北京) 211 双一流 2020年09月 - 2024年06月
软件工程 本科 全日制

实习经历

Shopee（北京） 2025年09月 - 至今

岗位描述：负责机器学习平台后端研发工作；负责流量调度服务后端研发工作；负责LLM-Gateway后端开发工作；

工作内容：

- **需求开发**：负责AIS平台**v1.18～v1.21**的需求开发。MLP内部业务通过**Istio**进行流量转发，基于原生能力进行服务端适配，平台控制面提供限流重试、状态重置等相关配置并落库同步至服务Pod；
- **插件开发**：推理流量通过**RPC服务**进行调度；将部分计算任务迁移为沙箱，在QPS 2k的情况下将请求的**P99 RT降低约5%；**
- **流量调度：**参与流量调度服务算法的若干实现，包括轮询、随机、前缀缓存等路由算法，使得平均推理 **TTFT** 降低约**13%**；
- **模型评估**：Maas产品化涉及**大模型压测**，需要在满足业务延迟条件下评估推理服务所能支持的最大**TPS**；在工程侧负责压测阶段的相关链路，同步至集群侧；支持自定义配置，以获取大模型**TU**、**TUPM**折算系数进行内部定价；
- **推理网关**：负责内部统一推理网关开发，**接入5+供应商，30+相关模型**，涵盖OpenAi、Anthropic等若干家供应商；涉及文本、视频、多模态、JEV等若干类型大模型，提供推理能力；
- **自动治理**：AIS内部推理服务需要研发手动治理告警；基于**OpenClaw**搭建治理Bot，扩展Skill及工具Tool，根据运维文档标准自动化治理实例，**支持扩容、重启**等相关运维操作，日均处理**20+**服务告警；

字节跳动（北京） 2025年03月 - 2025年07月

岗位描述：负责地理位置中台离线任务数据监控治理、内部AI专项提效；负责后端相关需求开发工作；

工作内容：

- **质量保障**：基于Bamboo平台，监控内部若干团队3k+ Hive表生产数据，检测维度包括异常表行数、数据异常波动率等；设计**DVAD算法**以适配波动率抖动情况。存量监控通过平台定时触发检测任务，增量表通过接口形式同步至平台侧；
- **告警治理**：质量保障的需求延伸。设计并搭建**告警推送链路**。统计群内未响应告警，设定Aily Agent及相关工具提取信息，对接飞书API，由WorkFlow主动触及相关RD，将告警ACK率从**40%**提升至**73%**；
- **反馈打标**：负责不同Oncall工单打标。设计并搭建RAG方式的打标链路，基于字节内部开放模型获取推理能力，并搭建存量Oncall工单知识库，在该链路上将工单的打标准确率从**50%提升至90%**；
- **MCP工具**：AIDP业务团队问答BOT需要扩展工具能力，负责设定相关参数及DB筛选条件，搭建内部数据库读写接口。

爱诗科技（北京） 2024年11月 - 2025年02月

岗位描述： 负责大规模分布式系统研发工作，优化系统性能；负责海量数据的获取、清洗、交付工作；

工作内容：

- **数据量**：内存使用量存在峰值抖动情况，定位原因为切片合并上传代码段。采取**子进程流式读取并落盘**，主进程**聚合元信息**，并调控多进程的**分配数量**，以解决32GB内存下数据处理的OOM问题；
- **流水线**：数据处理涉及多个流程，该功能点从DB角度映射Job、Task的Pre和Next状态，在上一个Job和对应Task完成后自动创建下一个**Jon的元信息**，以进行数据处理。目前支持**Job和Task级别**的流水线处理。
- **公平调度**：Master多实例调度Task状态，使用Redis分布式锁**隔离调度请求**，存在Corner情况**单实例多次调度**，通过**Redis List**和**Master UUID**，实现Redis的**轮转公平锁**以调度任务状态，确保多实例调度的顺序公平性。
- **心跳机制**：Worker节点不稳定，该机制通过记录**Task心跳**，由Worker节点定时更新，Master监控，进行切片重置；

项目经历

Compass-Gateway 2026年06月 - 至今

- **核心技术：**Golang、Python、Gin、Trace、MySQL、Redis、Kafka、Prometheus、Pipeline
- **项目描述：**Shopee内部大模型统一网关，提供MLP AIS平台推理服务及外部供应商模型服务。为Shopee内部用户提供模型推理能力。平台整体承载约 150+API 路由、20+模型供应商、200+模型。系统QPS 2000+。

主要功能点：

- **权限分配：**系统以**BU**、**Team**、**Project**维度进行权限拆分和分配，用户可根据自身权限自定义管理相关团队成员，并支持由PM进行Shopee、Garena、Migoo子公司级别的团队管控以及相关额度、模型可见性等若干配置。
- **预算配额：**团队预算方案存在差异，系统涵盖**CQP**、**AQP**、**DQP**等预算方案，其开放额度与内部IT Center**工单适配**，用户自定义提交工单以申请额度，系统根据工单状态做内部DB适配，以API-KEY形式对接用户额度，并进行相关额度的配置。
- **模型推理：**目前系统提供**内部MLP模型**推理服务和**外部供应商**模型服务，内部MLP平台推理模型服务根据单次推理的TU、TPM进行计费处理，外部供应商模型采用相关API的Token计价方式进行统一收费。
- **日志审计**：审计方式依赖HIve表，系统将单次推理请求通过Kafka同步至Hive表，配置**监控大盘**以并通过相关SQL聚合相关审计信息，以方便用户审查团队额度使用情况。在团队额度超出限额时自动发送相关通知信息。

TidalStation 2024年11月 - 2025年02月

- **核心技术**：MongoDB、Redis、Kubernetes、Docker、Thrift、MLP、VEPFS
- **项目描述**：分布式数据处理平台，旨在利用业务中的潮汐资源完成数据处理的业务支持。

主要功能点：

- **并行处理**：将数据集拆分为若干**切片**保存至MongoDB及Tos，对应若干Task，通过MLP平台启动若干实例并行处理数据；
- **任务调度**：Worker在获取任务后将信息同步至Master，由k8s负载将**流量分发**至Master实例监控任务运行状态，**轮询检测**Task状态并进行任务状态的调度，当前系统支持**3.8w/s**的轮询请求；
- **任务容错**：在启动闲时资源的情况下，单个Task存在因**资源调度**而失败的情况，系统支持在**非UDF失败**的情况下进行任务的**自动重试**，以适应火山资源动态分配的情况，在获得闲时资源后重新执行任务；
- **Pipeline**：数据集的处理涉及若干流程，该功能将多个数据处理流程合并为一条Pipeline，每条Pipeline将自动化处理流水线上的数据，并支持**批处理**模式及**伪流处理**模式，提升CPU及GPU的利用率；

研究经历

量子扩散模型渗透率场生成及其预测研究 2025年06月 - 2027年06月

- 量子注意力扩散模型（https://github.com/Anyoneself/quantum-attention-net）

面向二维非均质渗透率场重构，设计融合空间自注意力与参数化量子门控的 U-Net 扩散模型；在存档的原型辅助评估中取得 RMSE 0.01225，较 GAN 基线的 0.05466 降低 77.6%，并通过无网络对照分析原型注入对结果的影响。

- 量子PINN网路模型（https://github.com/Anyoneself/quantum-pinn-net）

面向稀疏观测下的渗透率场补全，设计量子启发的可学习周期相位编码与门控坐标网络；在 128 幅数值场、相同训练轮数下，原始预测 RMSE 较固定 FNN 网络基线降低 9%，并完成消融、抗噪及 Darcy 流动响应评估。

荣誉奖项

挑战杯人工智能+赛道国奖、蓝桥杯大赛省奖、全国大学生数学建模竞赛省奖、科技创新先进个人奖学金、校级奖学金若干

技术栈

- 语言：熟悉Go、Java、Python语法，熟悉常用数据结构及其相关使用；
- 数据库：熟悉MySQL，MongoDB；熟悉Redis相关业务场景；
- 框架：熟悉Web开发主流框架，如Spring全家桶、Gorm、Heartz等；
- 大模型：熟悉Transformer架构、Langchain、RAG、Agent等大模型相关技术；
- 工具：熟练掌握Git、Docker、kubernetes等开发工具；

其他

- **语言：** 英语（CET-6）