

刘元智

电话：15769057937 | 邮箱：1739727979@qq.com
年龄：24 岁 | 性别：男 | 政治面貌：共青团员

中国石油大学 CHINA UNIVERSITY OF PETROLEUM BEIJING

教育经历

中国石油大学 (北京) 211 双一流 2024 年 09 月 - 2027 年 06 月
计算机技术硕士全日制

中国石油大学 (北京) 211 双一流 2020 年 09 月 - 2024 年 06 月
软件工程本科全日制

实习经历

Shopee（北京） 2025 年 09 月 - 至今
岗位描述：负责机器学习平台后端研发工作；负责流量调度服务后端研发工作；负责 LLM-Gateway 后端开发工作；
工作内容：

- **需求开发：**负责 AIS 平台 **v1.18 ~ v1.21** 的需求开发。MLP 内部业务通过 **Istio** 进行流量转发，基于原生能力进行服务端适配，平台控制面提供限流重试、状态重置等相关配置并落库同步至服务 Pod；
- **插件开发：**推理流量通过 **RPC 服务**进行调度；将部分计算任务迁移为沙箱，在 QPS 2k 的情况下将请求的 **P99 RT 降低约 5%**；
- **流量调度：**参与流量调度服务算法的若干实现，包括轮询、随机、前缀缓存等路由算法，使得平均推理 **TTFT 降低约 13%**；
- **模型评估：**Maas 产品化涉及**大模型压测**，需要在满足业务延迟条件下评估推理服务所能支持的**最大 TPS**；在工程侧负责压测阶段的相关链路，同步至集群侧；支持自定义配置，以获取大模型 **TU**、**TUPM** 折算系数进行内部定价；
- **推理网关：**负责内部统一推理网关开发，**接入 5+ 供应商，30+ 相关模型**，涵盖 OpenAi、Anthropic 等若干家供应商；涉及文本、视频、多模态、JEV 等若干类型大模型，提供推理能力；
- **自动治理：**AIS 内部推理服务需要研发手动治理告警；基于 **OpenClaw** 搭建治理 Bot，扩展 Skill 及工具 Tool，根据运维文档标准自动化治理实例，**支持扩容**、**重启**等相关运维操作，日均处理 **20+** 服务告警；

字节跳动（北京） 2025 年 03 月 - 2025 年 07 月
岗位描述：负责地理位置中台离线任务数据监控治理、内部 AI 专项提效；负责后端相关需求开发工作；
工作内容：

- **质量保障：**基于 Bamboo 平台，监控内部若干团队 3k+ Hive 表生产数据，检测维度包括异常表行数、数据异常波动率等；设计 **DVAD 算法**以适配波动率抖动情况。存量监控通过平台定时触发检测任务，增量表通过接口形式同步至平台侧；
- **告警治理：**质量保障的需求延伸。设计并搭建**告警推送链路**。统计群内未响应告警，设定 Aily Agent 及相关工具提取信息，对接飞书 API，由 WorkFlow 主动触及相关 RD，将告警 ACK 率从 **40%** 提升至 **73%**；
- **反馈打标：**负责不同 Oncall 工单打标。设计并搭建 RAG 方式的打标链路，基于字节内部开放模型获取推理能力，并搭建存量 Oncall 工单知识库，在该链路上将工单的打标准确率从 **50% 提升至 90%**；
- **MCP 工具：**AIDP 业务团队问答 BOT 需要扩展工具能力，负责设定相关参数及 DB 筛选条件，搭建内部数据库读写接口。

爱诗科技（北京） 2024 年 11 月 - 2025 年 02 月
岗位描述：负责大规模分布式系统研发工作，优化系统性能；负责海量数据的获取、清洗、交付工作；
工作内容：

- **数据量：**内存使用量存在峰值抖动情况，定位原因为切片合并上传代码段。采取**子进程流式读取并落盘**，主进程**聚合元信息**，并调控多进程的**分配数量**，以解决 32GB 内存下数据处理的 OOM 问题；
- **流水线：**数据处理涉及多个流程，该功能点从 DB 角度映射 Job、Task 的 Pre 和 Next 状态，在上一个 Job 和对应 Task 完成后自动创建下一个 **Jon 的元信息**，以进行数据处理。目前支持 **Job 和 Task 级别**的流水线处理。
- **公平调度：**Master 多实例调度 Task 状态，使用 Redis 分布式锁**隔离调度请求**，存在 Corner 情况**单实例多次调度**，通过 **Redis List** 和 **Master UUID**，实现 Redis 的**轮转公平锁**以调度任务状态，确保多实例调度的顺序公平性。
- **心跳机制：**Worker 节点不稳定，该机制通过记录 **Task 心跳**，由 Worker 节点定时更新，Master 监控，进行切片重置；

项目经历

Compass-Gateway 2026 年 06 月 - 至今

- **核心技术：**Golang、Python、Gin、Trace、MySQL、Redis、Kafka、Prometheus、Pipeline
- **项目描述：**Shopee 内部大模型统一网关，提供 MLP AIS 平台推理服务及外部供应商模型服务。为 Shopee 内部用户提供模型推理能力。平台整体承载约 150+API 路由、20+ 模型供应商、200+ 模型。系统 QPS 2000+。

主要功能点：

- **权限分配：**系统以 **BU**、**Team**、**Project** 维度进行权限拆分和分配，用户可根据自身权限自定义管理相关团队成员，并支持由 PM 进行 Shopee、Garena、Migoo 子公司级别的团队管控以及相关额度、模型可见性等若干配置。
- **预算配额：**团队预算方案存在差异，系统涵盖 **CQP**、**AQP**、**DQP** 等预算方案，其开放额度与内部 IT Center **工单适配**，用户自定义提交工单以申请额度，系统根据工单状态做内部 DB 适配，以 API-KEY 形式对接用户额度，并进行相关额度的配置。
- **模型推理：**目前系统提供**内部 MLP 模型推理服务和外部供应商模型服务**，内部 MLP 平台推理模型服务根据单次推理的 TU、TPM 进行计费处理，外部供应商模型采用相关 API 的 Token 计价方式进行统一收费。
- **日志审计：**审计方式依赖 HIve 表，系统将单次推理请求通过 Kafka 同步至 Hive 表，配置**监控大盘**以并通过相关 SQL 聚合相关审计信息，以方便用户审查团队额度使用情况。在团队额度超出限额时自动发送相关通知信息。

TidalStation 2024 年 11 月 - 2025 年 02 月

- **核心技术：**MongoDB、Redis、Kubernetes、Docker、Thrift、MLP、VEPFS
- **项目描述：**分布式数据处理平台，旨在利用业务中的潮汐资源完成数据处理的业务支持。

主要功能点：

- **并行处理：**将数据集拆分为若干**切片**保存至 MongoDB 及 Tos，对应若干 Task，通过 MLP 平台启动若干实例并行处理数据；
- **任务调度：**Worker 在获取任务后将信息同步至 Master，由 k8s 负载将**流量分发**至 Master 实例监控任务运行状态，**轮询检测** Task 状态并进行任务状态的调度，当前系统支持 **3.8w/s** 的轮询请求；
- **任务容错：**在启动闲时资源的情况下，单个 Task 存在因**资源调度**而失败的情况，系统支持在**非 UDF 失败**的情况下进行任务的**自动重试**，以适应火山资源动态分配的情况，在获得闲时资源后重新执行任务；
- **Pipeline：**数据集的处理涉及若干流程，该功能将多个数据处理流程合并为一条 Pipeline，每条 Pipeline 将自动化处理流水线上的数据，并支持**批处理模式**及**伪流处理模式**，提升 CPU 及 GPU 的利用率；

研究经历

量子扩散模型渗透率场生成及其预测研究 2025 年 06 月 - 2027 年 06 月

- 量子注意力扩散模型（https://github.com/Anyoneself/quantum-attention-net）

面向二维非均质渗透率场重构，设计融合空间自注意力与参数化量子门控的 U-Net 扩散模型；在存档的原型辅助评估中取得 RMSE 0.01225，较 GAN 基线的 0.05466 降低 77.6%，并通过无网络对照分析原型注入对结果的影响。

- 量子 PINN 网路模型（https://github.com/Anyoneself/quantum-pinn-net）

面向稀疏观测下的渗透率场补全，设计量子启发的可学习周期相位编码与门控坐标网络；在 128 幅数值场、相同训练轮数下，原始预测 RMSE 较固定 FNN 网络基线降低 9%，并完成消融、抗噪及 Darcy 流动响应评估。

荣誉奖项

挑战杯人工智能 + 赛道国奖、蓝桥杯大赛省奖、全国大学生数学建模竞赛省奖、科技创新先进个人奖学金、校级奖学金若干

技术栈

- 语言：熟悉 Go、Java、Python 语法，熟悉常用数据结构及其相关使用；
- 数据库：熟悉 MySQL，MongoDB；熟悉 Redis 相关业务场景；
- 框架：熟悉 Web 开发主流框架，如 Spring 全家桶、Gorm、Heartz 等；
- 大模型：熟悉 Transformer 架构、Langchain、RAG、Agent 等大模型相关技术；
- 工具：熟练掌握 Git、Docker、kubernetes 等开发工具；

其他

- **语言：**英语（CET-6）